

텐서플로로 시작하는 딥러닝

# 4. Convolutional Neural Networks



Ha-Jin Yu, Dept. of Computer Science, University of Seoul

서울시립대학교 컴퓨터과학부 유하진

2019.

HJYU@UOS.AC.KR

# CHAPTER 4 Convolution filter를 통한 image 특징 추출

## 4.1 Convolution filter의 기능

### 4.1.1 Convolution filter의 예

### 4.1.2 Tensorflow를 이용한 convolution filter 적용

### 4.1.3 Pooling layer

## 4.2 Convolution filter를 이용한 image 분류

### 4.2.1 특징 변수를 이용한 image 분류

### 4.2.2 Convolution filter의 동적인 학습

## 4.3 Convolution filter를 이용한 필기 문자 분류

### 4.3.1 세션 정보의 저장 기능

### 4.3.2 단층 CNN을 이용한 필기 문자 분류

### 4.3.3 동적으로 학습된 filter 확인

# 4.1 Convolution Filter 의 기능

## 4.1.1 Convolution Filter 의 예


0.11	0.11	0.11
0.11	0.12	0.12
0.11	0.11	0.11

0.05	0.05	0.05
0.05	0.60	0.05
0.05	0.05	0.05

Fig 4-2 image 그레이�션 효과를 주는 filter의 예

- 각 pixel의 값에 가중치를 곱해서 합산한 값을 중앙 pixel의 값으로 치환
- 모든 가중치의 합계가 1

# Fig 4-3 Convolution Filter 의 적용 예



$$\begin{aligned} & 91 \times 0.11 + 46 \times 0.11 + 35 \times 0.11 \\ & + 141 \times 0.11 + 140 \times 0.12 + 135 \times 0.11 \\ & + 156 \times 0.11 + 153 \times 0.11 + 153 \times 0.11 = 116.9 \end{aligned}$$


# Filters

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

-1	0	1
-2	0	2
-3	0	3

Fig 4-4. 세로 edge를 추출하는 filter  
가로로 같은 색이 이어지면 +-상쇄  
• 결과가 음수이면 절대값

평균을 추출하는 filter




# Fig 4-5 세로와 가로 edge를 보다 두꺼운 폭으로 추출하는 filter

2	1	0	-1	-2
3	2	0	-2	-3
4	3	0	-3	-4
3	2	0	-2	-3
2	1	0	-1	-2

2	3	4	3	2
1	2	3	2	1
0	0	0	0	0
-1	-2	-3	-2	-1
-2	-3	-4	-3	-2

※ 실제로는 각 성분을 23.0으로 나눈 값을 사용한다

## 4.1.2 tensorflow를 이용한 convolution filter 적용



data 세트의 image data(일부)

# [OFE-01] 필요한 module을 import한다.

```
import tensorflow as tf
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import cPickle as pickle      # image data 를 읽기 위한 module, Python 2 만 가능
```

# [OFE-02] data file 'ORENIST.data'에서 image와 label data를 읽어들인다.

```
with open('ORENIST.data', 'rb') as file:
```


```
    images, labels = pickle.load(file)
```

```
# colab 에 file upload
from google.colab import files
uploaded = files.upload()
for fn in uploaded.keys():
    print('User uploaded file "{name}" with length {length} bytes'.format(
        name=fn, length=len(uploaded[fn])))
```

# [OFE-03] Show image data samples


```
fig = plt.figure(figsize=(10,5))
for i in range(40):
    subplot = fig.add_subplot(4, 10, i+1)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.set_title('%d' % np.argmax(labels[i]))
    subplot.imshow(images[i].reshape(28,28), vmin=0, vmax=1,
                   cmap=plt.cm.gray_r, interpolation='nearest')
```

# Fig 4-7 Color image에 대한 convolution filter 적용



Filter size (세로x가로), num of input layers, num of filters

# Fig 4-8 Gray scale image 에 대한 convolution filter 적용



[5,5,1,2]

Filter size (세로x가로), num of input layers, num of filters

# # [OFE-04] filter 정보를 저장한 다차원 list를 만드는 함수를 준비

```
def edge_filter():
    filter0 = np.array(
        [[ 2, 1, 0,-1,-2],
         [ 3, 2, 0,-2,-3],
         [ 4, 3, 0,-3,-4],
         [ 3, 2, 0,-2,-3],
         [ 2, 1, 0,-1,-2]]) / 23.0
    filter1 = np.array(
        [[ 2, 3, 4, 3, 2],
         [ 1, 2, 3, 2, 1],
         [ 0, 0, 0, 0, 0],
         [-1,-2,-3,-2,-1],
         [-2,-3,-4,-3,-2]]) / 23.0
```

```
filter_array = np.zeros([5,5,1,2])
filter_array[:, :, 0, 0] = filter0
filter_array[:, :, 0, 1] = filter1

return tf.constant(filter_array, dtype=tf.float32)
```

Filter size (세로x가로), num of input layers,  
num of output layers

Session 내에서 사용하는 값은 모두 tensorflow  
object로 준비

# [OFE-05] Image data에 filter를 적용하는 계산식을 준비

```
x = tf.placeholder(tf.float32, [None, 784])
```

```
x_image = tf.reshape(x, [-1,28,28,1])
```

```
W_conv = edge_filter()
```

```
h_conv = tf.abs(tf.nn.conv2d(x_image, W_conv,  
    strides=[1,1,1,1], padding='SAME'))
```

```
h_conv_cutoff = tf.nn.relu(h_conv-0.2)
```

```
h_pool = tf.nn.max_pool(h_conv_cutoff, ksize=[1,2,2,1],  
    strides=[1,2,2,1], padding='SAME')
```

input

# of images x size(row x col) x # of layers  
-1 : undefined

abs: 결과가 음수이면 절대값

[1, dy, dx, 1]  
[1,1,1,1] : 모든 값 계산

SAME  
VALID → reduced

Stride [2,2]

Cutoff : 0.2보다 작은 값을 0으로

# [OFE-06] 세션을 준비하고 Variable을 초기화

```
sess = tf.InteractiveSession()
```

```
sess.run(tf.global_variables_initializer())
```

## [OFE-07] 최초 9개의 image data에 대해 convolution filter를 적용한 결과를 계산

```
filter_vals, conv_vals = sess.run([W_conv, h_conv_cutoff],
```

```
    feed_dict={x:images[:9]})
```

Image 중 첫 9개

# of images x size(row x col) x # of output layers

```
# [OFE-08] 얻어진 결과를 image로 output
```

```
fig = plt.figure(figsize=(10,3))
```

```
for i in range(2):
```

```
    subplot = fig.add_subplot(3, 10, 10*(i+1)+1)
```

```
    subplot.set_xticks([])
```

```
    subplot.set_yticks([])
```

```
    subplot.imshow(filter_vals[:, :, 0, i], cmap=plt.cm.gray_r, interpolation='nearest')
```

```
v_max = np.max(conv_vals)
```

filter 적용 후 Image 값이 1보다 커질 가능성이 있으므로


```
for i in range(9):
```

```
    subplot = fig.add_subplot(3, 10, i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.set_title('%d' % np.argmax(labels[i]))
    subplot.imshow(images[i].reshape((28,28)), vmin=0, vmax=1,
                   cmap=plt.cm.gray_r, interpolation='nearest')
```

```
    subplot = fig.add_subplot(3, 10, 10+i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.imshow(conv_vals[i,:,:,:0], vmin=0, vmax=v_max,
                   cmap=plt.cm.gray_r, interpolation='nearest')
```

```
    subplot = fig.add_subplot(3, 10, 20+i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.imshow(conv_vals[i,:,:,:1], vmin=0, vmax=v_max,
                   cmap=plt.cm.gray_r, interpolation='nearest')
```

# Fig 4-11 convolution filter와 pooling layer를 적용한 결과



## 4.1.3 Pooling layer





Fig 4-10 pooling layer

- Image 를  $2 \times 2$  block 으로 분해
  - 각각의 block 을 하나의 pixel로 치환 (maximum)
  - $28 \times 28$  image  $\rightarrow 14 \times 14$  image
- tf.nn.max\_pool(h\_conv\_cutoff, ksize=[1,2,2,1], strides=[1,2,2,1], padding='SAME')  
tf.nn.avg\_pool : average

# Pooling layer를 적용한 결과

- 28x28 → 14x14 : 대략적인 특징만 유지 → 특징을 이용하여 image 분류



## 4.2 Image classification using convolution filter

### 4.2.1 Image classification using feature vectors




그림 4-12 이미지 데이터를 특징 변수로 변환하는 신경망

# Image classification using convolution filter

# [OCE-05] pooling layer의 output을 fully connected layer와 softmax function으로 된 '확장된 output layer'으로 input하는 계산식을 준비한다.

```
h_pool_flat = tf.reshape(h_pool, [-1, 392])
```

```
num_units1 = 392
```

14x14x2

```
num_units2 = 2
```

```
w2 = tf.Variable(tf.truncated_normal([num_units1, num_units2]))
```

```
b2 = tf.Variable(tf.zeros([num_units2]))
```

```
hidden2 = tf.nn.tanh(tf.matmul(h_pool_flat, w2) + b2)
```

```
w0 = tf.Variable(tf.zeros([num_units2, 3]))
```

```
b0 = tf.Variable(tf.zeros([3]))
```

```
p = tf.nn.softmax(tf.matmul(hidden2, w0) + b0)
```

# 나머지는 전과 동일

→ 정답율 100%

# 특징변수 ( $z_1, z_2$ ) 산포도

# [OCE-09] 각각의 data의 특징변수 ( $z_1, z_2$ )를 산포도로 나타낸다.

```
hidden2_vals = sess.run(hidden2, feed_dict={x:images})
```

```
z1_vals = [[],[],[]] # label 0,1,2
```

```
z2_vals = [[],[],[]]
```

```
for hidden2_val, label in zip(hidden2_vals, labels):
```

```
    label_num = np.argmax(label)
```

```
    z1_vals[label_num].append(hidden2_val[0])
```

```
    z2_vals[label_num].append(hidden2_val[1])
```

```
fig = plt.figure(figsize=(5,5))
```


```
subplot = fig.add_subplot(1,1,1)
```

```
subplot.scatter(z1_vals[0], z2_vals[0], s=200, marker='|')
```

```
subplot.scatter(z1_vals[1], z2_vals[1], s=200, marker='_')
```

```
subplot.scatter(z1_vals[2], z2_vals[2], s=200, marker='+')
```

# Fig 4-13 Feature variables ( $z_1$ , $z_2$ )



## 4.2.2 Convolution filter의 동적인 학습

- 특징 추출
- 세로막대, 가로막대
  - 사선, 원형, 곡선, 점 ... ?
  - 자동 학습
  - Filter 를 weights와 같이 학습
  - $W_{\text{conv}} = \text{constant} \rightarrow \text{variable}$

# ORENIST dynamic filter example.ipynb

# [ODE-03] image data에 filter와 pooling layer을 적용하는 계산식을 준비한다.

```
x = tf.placeholder(tf.float32, [None, 784])
```

```
x_image = tf.reshape(x, [-1,28,28,1])
```

```
W_conv = tf.Variable(tf.truncated_normal([5,5,1,2], stddev=0.1))
```

```
h_conv = tf.abs(tf.nn.conv2d(x_image, W_conv,
```

```
strides=[1,1,1,1], padding='SAME'))
```


```
h_conv_cutoff = tf.nn.relu(h_conv-0.2)
```

```
h_pool =tf.nn.max_pool(h_conv_cutoff, ksize=[1,2,2,1],
```


```
strides=[1,2,2,1], padding='SAME')
```

size(row x col) x # of input layers x # of output layers

# Fig 4-14 convolution filter를 동적으로 학습한 결과



Convolution  
result



Pooling  
layer  
result

# 4.3 convolution filter를 이용한 필기 문자 분류

4.3.1 세션 정보의 저장 기능

4.3.2 단층 CNN을 이용한 필기 문자 분류

4.3.3 동적으로 학습된 filter 확인

## 4.3.1 세션 정보의 저장 기능

- 트레이닝을 실행하는 도중에 세션 상태를 저장
- 트레이닝을 중단하더라도 나중에 다시 재개 가능
- saver = tf.train.Saver()

# MNIST dynamic filter classification.jpynb

- saver = tf.train.Saver()
- saver.save(sess, '/tmp/mdc\_session', global\_step=i)
- '/tmp/mdc\_session' 디렉터리에 'mdc\_session-<처리 횟수>' 및 'mdc\_session-<처리 횟수>.meta'라는 파일이 생성
- 이전 5회까지의 파일만 저장되고, 그보다 오래된 파일은 자동으로 삭제
- saver.restore(sess, '/tmp/mdc\_session-4000')
- 복원
  - 먼저 각종 계산식을 원래 세션과 동일하게 정의
  - 세션을 준비하고 Variable을 초기화
  - tf(train.Saver) 오브젝트를 준비하고 restore 메소드를 호출

# Parameter optimization with saver

```
i = 0
for _ in range(4000):
    i += 1
    batch_xs, batch_ts = mnist.train.next_batch(100)
    sess.run(train_step, feed_dict={x: batch_xs, t: batch_ts})
    if i % 100 == 0:
        loss_val, acc_val = sess.run([loss, accuracy],
                                     feed_dict={x:mnist.test.images, t:mnist.test.labels})
        print ('Step: %d, Loss: %f, Accuracy: %f'
              % (i, loss_val, acc_val))
    saver.save(sess, '/tmp/mdc_session', global_step=i)
```

## 4.3.2 단층 CNN을 이용한 필기 문자 분류




Fig 4-15 convolution filter와 pooling layer를 추가한 신경망

# MNIST dynamic filter classification.ipynb

- Filter의 개수 : 임의로 지정 → 16

# [MDC-03] filter에 해당하는 Variable을 준비하고 input data에 filter와 pooling layer를 적용하는 계산식을 정의

```
num_filters = 16
```

```
x = tf.placeholder(tf.float32, [None, 784])
```

```
x_image = tf.reshape(x, [-1,28,28,1])
```

```
W_conv = tf.Variable(tf.truncated_normal([5,5,1,num_filters],  
stddev=0.1))
```

```
h_conv = tf.nn.conv2d(x_image, W_conv,  
strides=[1,1,1,1], padding='SAME')      # 특징추출 (음수 가능)
```

```
h_pool = tf.nn.max_pool(h_conv, ksize=[1,2,2,1],  
strides=[1,2,2,1], padding='SAME')
```

# [MDC-04] pooling layer의 output을 전 결합층을 경유해서 소프트맥스 함수로 input하는 계산식을 정의한다.

```
h_pool_flat = tf.reshape(h_pool, [-1, 14*14*num_filters])
```

```
num_units1 = 14*14*num_filters
```

```
num_units2 = 1024
```

```
w2 = tf.Variable(tf.truncated_normal([num_units1, num_units2]))
```

```
b2 = tf.Variable(tf.zeros([num_units2]))
```

```
hidden2 = tf.nn.relu(tf.matmul(h_pool_flat, w2) + b2)
```

```
w0 = tf.Variable(tf.zeros([num_units2, 10]))
```

```
b0 = tf.Variable(tf.zeros([10]))
```

```
p = tf.nn.softmax(tf.matmul(hidden2, w0) + b0)
```

# [MDC-05] 오차 함수 loss, 트레이닝 알고리즘 train\_step, 정답률 accuracy를 정의한다.

```
t = tf.placeholder(tf.float32, [None, 10])           default = 0.001
loss = -tf.reduce_sum(t * tf.log(p))
train_step = tf.train.AdamOptimizer(0.0005).minimize(loss)
correct_prediction = tf.equal(tf.argmax(p, 1), tf.argmax(t, 1))
accuracy = tf.reduce_mean(tf.cast(correct_prediction, tf.float32))
```

# [MDC-06] 세션을 준비하고 Variable을 초기화한다.

```
sess = tf.InteractiveSession()
sess.run(tf.global_variables_initializer())
saver = tf.train.Saver()
```

```
# [MDC-07] 파라미터 최적화를 4000회 반복한다
# 최종적으로 테스트 세트에 대해 약 98%의 정답률을 얻을 수 있다.
i = 0
for _ in range(4000):
    i += 1
    batch_xs, batch_ts = mnist.train.next_batch(100)
    sess.run(train_step, feed_dict={x: batch_xs, t: batch_ts})
    if i % 100 == 0:
        loss_val, acc_val = sess.run([loss, accuracy],
                                     feed_dict={x:mnist.test.images, t:mnist.test.labels})
        print ('Step: %d, Loss: %f, Accuracy: %f'
              % (i, loss_val, acc_val))
    saver.save(sess, '/tmp/mdc_session', global_step=i)
```

### 4.3.3 동적으로 학습된 filter 확인

# [MDR-06] 세션을 준비하고 Variable을 초기화한 후, 최적화 처리를 마친 세션을 복원한다.

```
sess = tf.InteractiveSession()  
sess.run(tf.global_variables_initializer())  
saver = tf.train.Saver()  
saver.restore(sess, '/tmp/mdc_session-4000')
```

# [MDR-07] convolution filter의 값과 최초 9개의 image data에 대해 convolution filter와 pooling layer을 적용한 결과를 얻는다.

```
filter_vals, conv_vals, pool_vals = sess.run(  
    [W_conv, h_conv, h_pool],  
    feed_dict={x:mnist.test.images[:9] })
```

```
# [MDR-08] convolution filter를 적용한 결과를 image로 output한다.  
# convolution filter를 적용한 후에는 픽셀값이 음의 값을 갖는 경우도 있으  
므로 배경(픽셀값 0) 부분이 흰색이 되지 않는다는 점에 주의
```

```
fig = plt.figure(figsize=(10, num_filters+1))  
  
for i in range(num_filters):  
    subplot = fig.add_subplot(num_filters+1, 10,  
                             10*(i+1)+1)  
    subplot.set_xticks([])  
    subplot.set_yticks([])  
    subplot.imshow(filter_vals[:, :, 0, i],  
                  cmap=plt.cm.gray_r, interpolation='nearest')
```

```
for i in range(9):
    subplot = fig.add_subplot(num_filters+1, 10, i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.set_title('%d' %
                      np.argmax(mnist.test.labels[i]))
    subplot.imshow(mnist.test.images[i].reshape((28,28)),
                  vmin=0, vmax=1,
                  cmap=plt.cm.gray_r, interpolation='nearest')
```

```
for f in range(num_filters):
    subplot = fig.add_subplot(num_filters+1, 10,
                             10*(f+1)+i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.imshow(conv_vals[i,:,:,:,f],
                  cmap=plt.cm.gray_r, interpolation='nearest')
```

# [MDR-09] 마찬가지로 convolution filter와 pooling layer을 적용한 결과를 image로 output한다.

```
fig = plt.figure(figsize=(10,num_filters+1))
for i in range(num_filters):
    subplot = fig.add_subplot(num_filters+1, 10,
                             10*(i+1)+1)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.imshow(filter_vals[:, :, 0, i],
                  cmap=plt.cm.gray_r, interpolation='nearest')
```

```

for i in range(9):
    subplot = fig.add_subplot(num_filters+1, 10, i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.set_title('"%d" %  



                      np.argmax(mnist.test.labels[i])))
    subplot.imshow(mnist.test.images[i].reshape((28,28)),
                  vmin=0, vmax=1,
                  cmap=plt.cm.gray_r, interpolation='nearest')

for f in range(num_filters):
    subplot = fig.add_subplot(num_filters+1, 10,
                             10*(f+1)+i+2)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.imshow(pool_vals[i,:,:,:,f],
                  cmap=plt.cm.gray_r, interpolation='nearest')

```

# Filters

- 배경색이 하얗지 않은 이유 : 음수 픽셀값



```

# [MDR-10] 올바르게 분류할 수 없었던 몇몇 data에 대해 각각의 문자일 확률을 확인
fig = plt.figure(figsize=(12,10))
c=0
for (image, label) in zip(mnist.test.images,mnist.test.labels):
    p_val = sess.run(p, feed_dict={x:[image]})
    pred = p_val[0]
    prediction, actual = np.argmax(pred), np.argmax(label)
    if prediction == actual:
        continue
    subplot = fig.add_subplot(5,4,c*2+1)
    subplot.set_xticks([])
    subplot.set_yticks([])
    subplot.set_title('%d / %d' % (prediction, actual))
    subplot.imshow(image.reshape((28,28)), vmin=0, vmax=1,
                   cmap=plt.cm.gray_r, interpolation="nearest")
    subplot = fig.add_subplot(5,4,c*2+2)
    subplot.set_xticks(range(10))
    subplot.set_xlim(-0.5,9.5)
    subplot.set_ylim(0,1)
    subplot.bar(range(10), pred, align='center')
    c += 1
    if c == 10:
        break

```

